ДОМАШНЕЕ ЗАДАНИЕ 1 · LLM

Что на самом деле работает в RAG?

Четыре гипотезы на корпусе о психологии близких отношений

Чиркова Анна · MFAI-01

ДАННЫЕ И МОДЕЛИ

Корпус и пайплайн

10
научных статей на русском, из PDF, без служебной разметки

7 752
слов в самом длинном документе, в самом коротком — 355

3 230
слов в среднем на документ

Корпус 10 txt → **Chunking** 3 способа → **E5-small** 384 измерения → **Chroma** cosine → **Поиск** 3 метода → **Qwen 0.5B** top-k chunks

Каждая гипотеза меняет одно звено, остальные остаются теми же.

МЕТРИКА

Как я измеряла качество поиска

$$\text{Recall@k} = \frac{\text{релевантные в top-k}}{\text{все релевантные}}$$

Релевантные chunks для каждого вопроса я **разметила вручную** — обычно 1–2.

Ответ разрезан на 2 chunks, а нашёлся один → **0.5**.

```
def recall_at_k(retrieved_ids, relevant_ids):
    relevant = set(relevant_ids)
    if not relevant:
        return 0.0
    return len(set(retrieved_ids) & relevant) / len(relevant)  # доля найденных
```

ГИПОТЕЗА 1 · OVERLAP

Fixed-size: 200 токенов, overlap 0 или 40

```
def fixed_size_chunking(document_id, token_ids, chunk_size=200, overlap=0):
    chunks = []
    chunk_id = 0
    for start in range(0, len(token_ids), chunk_size - overlap):  # шаг 200 - 40 = 160
        end = min(start + chunk_size, len(token_ids))
        chunk_token_ids = token_ids[start:end]
        chunk_text = tokenizer.decode(chunk_token_ids)
        chunks.append({...})  # id, start_token, end_token, text
        chunk_id += 1
        if end == len(token_ids):
            break
```

Токены, а не слова

Считаю токенизатором E5: в doc_01 4 673 слова = 8 104 токена

Окно с шагом 160

Старты 0, 160, 320… — последние 40 токенов повторяются

Две коллекции

Chroma: 300 chunks без overlap и 369 с overlap

ГИПОТЕЗА 1 · OVERLAP

Вопросы на границе chunks

10 вопросов, по одному на документ. Для каждого я печатала конец chunk i и начало chunk i+1 и искала место, где мысль рвётся. Пример — q2:

«Что следует делать с дисфункциональными способами регулирования семейных конфликтов и почему?»

doc_02_chunk_16 · конец

…Полное «избавление» от дисфункциональных способов неосуществимо. Однако необходима и возможна их

doc_02_chunk_17 · начало

минимизация, поскольку они не влекут за собой позитивного разрешения конфликта…

С overlap граница сдвигается, и **chunk_21 содержит предложение целиком** — ответ в одном куске.

ГИПОТЕЗА 1 · OVERLAP

Результат: маленький плюс за заметную цену

Вариант	Chunks	Recall@1	Recall@3	Recall@5	Память
Без overlap	300	0.25	0.60	0.70	0.44 МБ
Overlap 40 токенов	369	0.20	0.55	0.75	0.54 МБ

+23 %

chunks: 300 → 369, память эмбеддингов +0.10 МБ

+0.05

Recall@5: 0.70 → 0.75 — единственный выигрыш

−0.05

Recall@1 и Recall@3 даже немного упали

ГИПОТЕЗА 1 · OVERLAP

Где overlap помог, а где — нет

ПОМОГ · +0.5

q2

Без overlap в top-5 только одна половина ответа. Chunk_21 с целым предложением находится → recall 1.0.

ПОМОГ · +0.5

q8

Все четыре числа (24 %, 7,7 %, 60 %, 86,5 %) попали в один chunk_62 — он на 1-м месте.

НАВРЕДИЛ · −0.5

q4

Нужный chunk есть, но выпал из top-5: в doc_04 много похожих кусков про ревность, а overlap добавил почти-дубликаты.

Остальные 7 вопросов — без изменений. **Overlap чинит разрыв предложения, но не ранжирование.**

ГИПОТЕЗА 2 · SEMANTIC CHUNKING

Граница — там, где падает сходство

```
sentences = [item.text.strip() for item in sentenize(text)]  # razdel
sentence_embeddings = embedding_model.encode(
    ["query: " + sentence for sentence in sentences], normalize_embeddings=True)
similarities = np.sum(sentence_embeddings[:-1] * sentence_embeddings[1:], axis=1)
threshold = float(np.percentile(similarities, percentile))  # 25

boundaries = [0]
for index, similarity in enumerate(similarities, start=1):
    if similarity < threshold:
        boundaries.append(index)
```

Cosine соседей

Векторы нормированы, значит скалярное произведение = cosine

Порог по документу

25-й перцентиль: ~четверть переходов становится границами

Лимит длины

Куски длиннее 450 токенов режу дальше: E5 видит до 512

ГИПОТЕЗА 2 · SEMANTIC CHUNKING

Один фрагмент doc_02 — два способа резать

Fixed-size, без overlap

chunk_16 · конец

…Полное «избавление» от дисфункциональных способов неосуществимо. Однако необходима и возможна их

chunk_17 · начало

минимизация, поскольку они не влекут за собой позитивного разрешения конфликта…

Semantic

semantic_26 · целиком

Полное «избавление» от дисфункциональных способов неосуществимо.

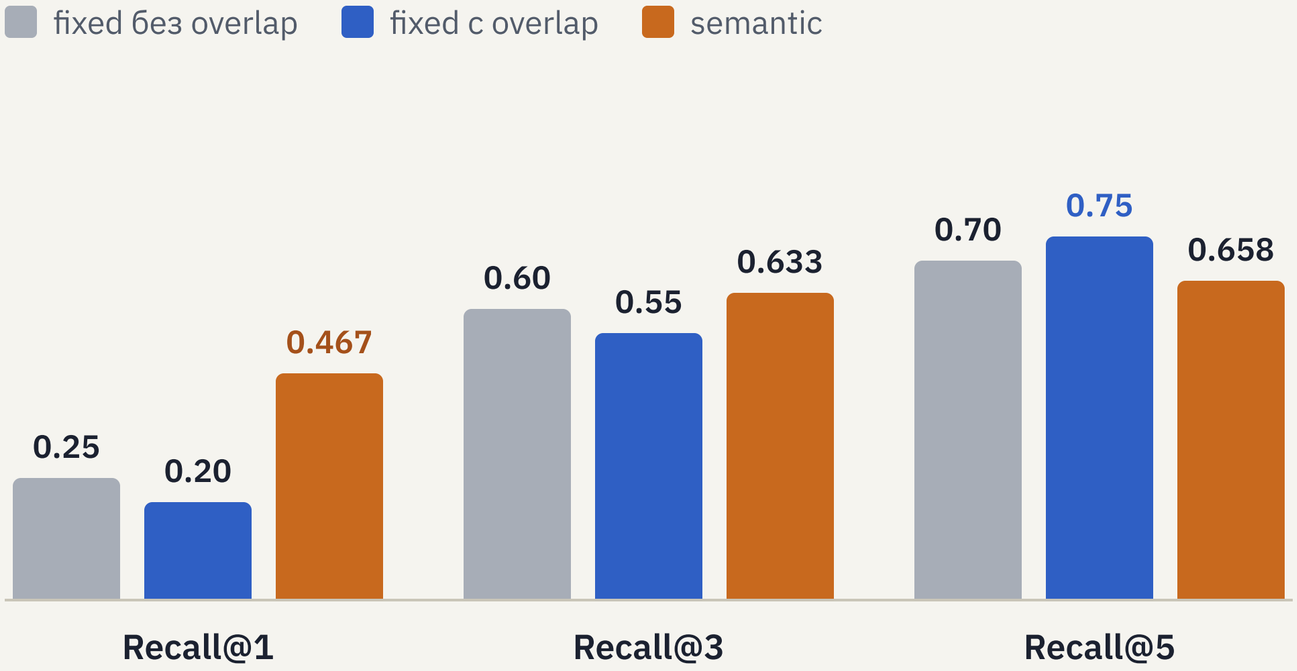
semantic_27 · целиком

Однако необходима и возможна их минимизация, поскольку они не влекут за собой позитивного разрешения конфликта, способствуют его усугублению.

Semantic не рвёт предложения, но разделил мысль из двух предложений: в semantic_27 «их» без слова «дисфункциональные» → **на q2 Recall@5 = 0**.

ГИПОТЕЗА 2 · SEMANTIC CHUNKING

Лучший на top-1, худший на top-5



420
смысловых chunks (fixed — 300)

90
токенов — медиана (fixed — 200)

83
куска короче 20 токенов — обрывки

30
упёрлись в лимит 450 токенов

Честная оговорка: у fixed без overlap на каждый вопрос 2 релевантных chunk, поэтому его Recall@1 не может быть выше 0.5.

ГИПОТЕЗА 3 · HYBRID SEARCH

BM25 + Dense, слияние через RRF

```
def bm25_tokenize(text):
    text = text.lower().replace("ё", "е")
    return re.findall(r"[а-яa-z0-9]+(?:[,.=-][0-9]+)?", text)  # «0,779306» — один токен

def rrf_ranking(question, n=20, candidate_count=60, rrf_k=60):
    dense_ids = dense_ranking(question, candidate_count)
    bm25_ids = bm25_ranking(question, candidate_count)
    scores = {}
    for ranking in (dense_ids, bm25_ids):
        for rank, chunk_id in enumerate(ranking, start=1):
            scores[chunk_id] = scores.get(chunk_id, 0) + 1 / (rrf_k + rank)
    return [chunk_id for chunk_id, _ in sorted(scores.items(), key=lambda x: x[1], reverse=True)[:n]]
```

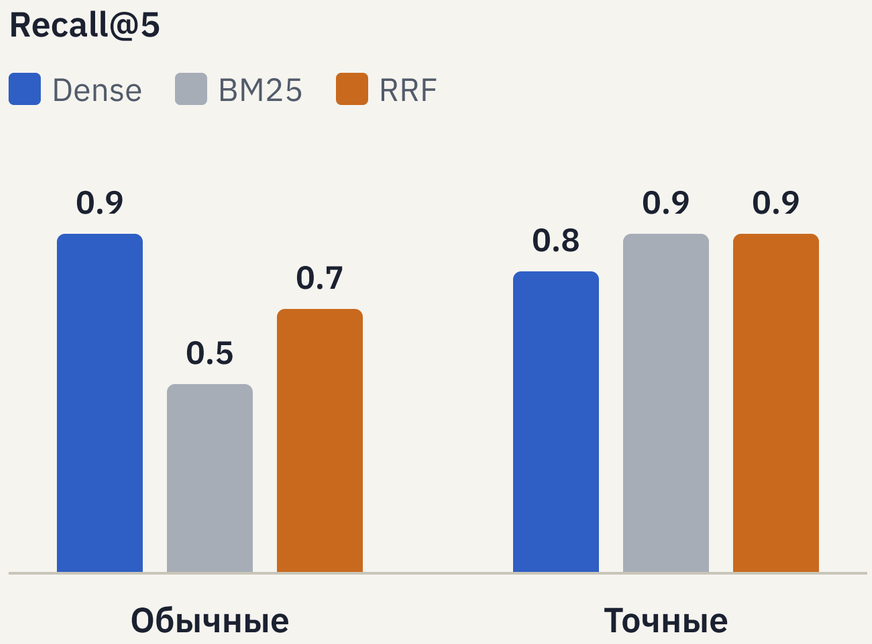
BM25Okapi из rank_bm25 · те же 369 chunks с overlap · каждый метод даёт 60 кандидатов · k = 60

ГИПОТЕЗА 3 · HYBRID SEARCH

3 метода × 2 типа вопросов

Вопросы	Метод	Recall@1	Recall@3	Recall@5
Обычные	Dense	0.00	0.50	0.90
Обычные	BM25	0.50	0.50	0.50
Обычные	RRF	0.10	0.70	0.70
Точные	Dense	0.50	0.80	0.80
Точные	BM25	0.90	0.90	0.90
Точные	RRF	0.50	0.70	0.90

Синим — лучший метод в группе. Точные вопросы содержат ACRS, Pphubbing, r=0,532, −0,779306, «52 % мужчин».



Средний Recall@5: **Dense 0.85** · RRF 0.80 · BM25 0.70 — гипотеза подтвердилась только частично.

ГИПОТЕЗА 3 · HYBRID SEARCH

Почему гибрид не обогнал Dense

hard_3 · «коэффициенты −0,779306 и 0,613170»

27	1	5
место в Dense	место в BM25	место в RRF

`1/61 + 1/87 ≈ 0.028`

q2 · «дисфункциональными способами…»

4	> 60	> 20
место в Dense	в BM25	в RRF

`1/64 ≈ 0.016 < чужой chunk 1/61 + 1/67 ≈ 0.031`

RRF награждает согласие двух списков. Если один метод прав, а второй ошибается, правильный chunk проигрывает «средним в обоих».

BM25 без лемматизации: «дисфункциональными» ≠ «дисфункциональных», поэтому на смысловых вопросах он чаще шумит.

ГИПОТЕЗА 4 · ВАРИАНТ B

Сколько chunks давать модели: k = 1, 3, 5, 10

Генерация

- Поиск — Dense, лучший метод из гипотезы 3
- Модель — Qwen2.5-0.5B-Instruct, локально
- Жадная генерация, до 60 новых токенов
- Системный промпт: «отвечай только по контексту, если факта нет — скажи»

Оценка 1–5 (автоматическая)

```
round(1 + 3·coverage + grounding)
```

coverage — доля ключевых фактов в ответе (q8: «24», «7,7», «60», «86,5»)

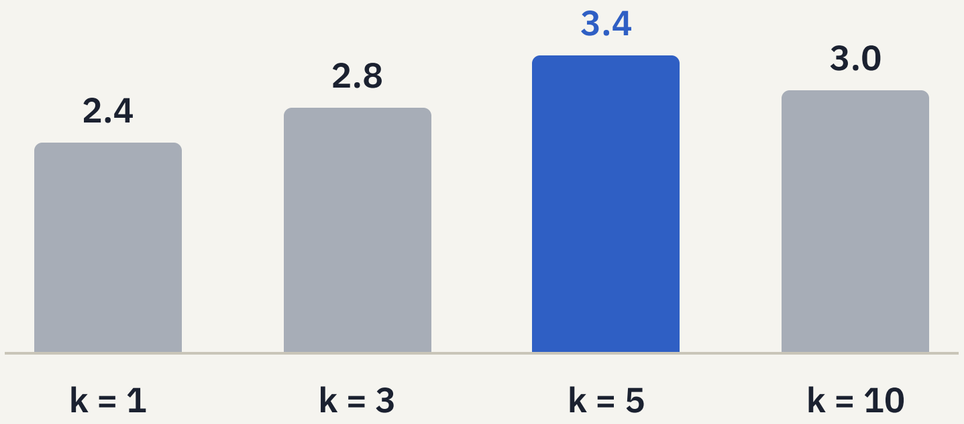
grounding — доля слов ответа, которые есть в контексте

рисковый ответ — grounding < 0.55

ГИПОТЕЗА 4 · ВАРИАНТ B

Лучший результат — при k = 5

Средняя оценка из 5



k	Оценка	Полнота	Опора	Рисковые
1	2.4	0.267	0.590	50 %
3	2.8	0.317	0.727	20 %
5	3.4	0.483	0.785	0 %
10	3.0	0.383	0.809	10 %

k = 1: не хватает второй половины ответа.

k = 10: опора на контекст растёт, а полнота фактов падает — модель теряется в лишнем тексте.

ГИПОТЕЗА 4 · ВАРИАНТ B

q8: нужный chunk найден, а ответ — нет

КОНТЕКСТ · CHUNK_62, 1-Е МЕСТО

«24 % мужчин поколения Z полагают, что контролировать детей-школьников должна женщина, в то время как так же считают 7,7 % женщин. Вариант „могут выполнять оба супруга“ выбрали 60 % мужчин и 86,5 % женщин.»

ОТВЕТ QWEN · K = 3 · ОЦЕНКА 2

«Мужчины поколения Z полагают, что контролировать детей-школьников должен женщина, тогда как женщины думают, что это должно быть сделано мужчинами.»

Ни одного числа, а вторая половина искажена.

Хороший retrieval ≠ хороший ответ. Маленькая модель не извлекла факт даже из первого chunk; при любом k оценка на q8 — 2.

ИТОГ

Что работает на моём корпусе

Приём	Результат	Вывод
Overlap 20 %	Recall@5 0.70 → 0.75, +23 % chunks	Небольшой плюс, есть цена
Semantic	Recall@1 0.47, но Recall@5 0.66	Точнее первый результат, хуже полнота
BM25	Точные вопросы: Recall@5 0.90	Нужен для чисел и терминов
RRF-гибрид	Средний Recall@5 0.80 < Dense 0.85	Без настройки не выигрывает
top-k	Лучший k = 5: 3.4 из 5	Больше контекста ≠ лучше

Рабочая настройка: **fixed 200 + overlap 40, Dense, top-k = 5**, а BM25 — как отдельный сигнал для точных запросов.

ИТОГ

Ограничения и что я бы улучшила

Ограничения

- 10 вопросов: один вопрос двигает среднее на 0.05–0.1
- Разметка ручная, число релевантных chunks у способов разное
- Оценка ответов — по ключевым словам, не экспертная
- Qwen 0.5B и лимит 60 токенов — часть ошибок от генератора

Что дальше

- Считать ещё hit@k — нашёлся ли хоть один нужный chunk
- Semantic: склеивать слишком короткие куски
- BM25 с лемматизацией (pymorphy)
- Веса в RRF или reranker; модель крупнее

В RAG нельзя улучшать одну часть отдельно

Overlap меняет размер базы, chunking — форму контекста, поиск — то, какие запросы находятся, а top-k — то, что увидит модель.

Спасибо! Готова ответить на вопросы.